

PF-3311 Agentes Virtuales Inteligentes

Documento de Avance – Entregable 2

Archibot: Evaluación del Efecto de un Agente Virtual Corporizado sobre la Confianza Percibida y la Naturalidad de Interacción en Sistemas de Consulta Documental basados en RAG

Estudiante: Marco Antonio Jiménez Gutiérrez **Correo:** marjimgu@gmail.com

I Ciclo, 2026 Fecha: 1 de junio de 2026

a) Resumen de Cambios desde el Entregable 1

Feedback recibido

El Entregable 1 obtuvo una calificación promedio de **4.54 / 5** (PR: 4.50 | RQ: 4.50 | CA: 5.00 | VT: 4.17). Los aspectos valorados positivamente fueron:

- El enfoque sobre normativa compleja es pertinente y el problema es real.
- La idea resulta muy adecuada dada la cantidad de archivos que maneja el sistema.
- El proyecto delimita bien el alcance y las preguntas de investigación.
- El planteamiento de medir eficiencia y precisión fue bien recibido.

Las sugerencias de mejora fueron las siguientes:

- **Las RQs son escuetas:** se sugirió ampliarlas y hacerlas más específicas.
- **Investigar permisos para viabilidad:** se cuestionó si era necesaria aprobación del CEC.
- **Justificar la necesidad del AVC:** no quedaba claro el valor diferencial del agente corporizado frente a un chat textual equivalente.

Cambios realizados

Aspecto	Cambio realizado	Justificación
RQs escuetas	Las tres RQs fueron reformuladas con mayor especificidad: se explicita la comparación AVC vs. interfaz textual, los constructos medidos (confianza, naturalidad, usabilidad, retención) y el dominio de aplicación (consulta de expedientes documentales).	Responde directamente a la sugerencia de ampliar las preguntas de investigación.
Permisos / viabilidad	Se adoptó diseño de estudio piloto con expertos (investigadores y profesionales con experiencia en HCI o sistemas documentales), lo que no requiere aprobación del CEC de la UCR. Esto se documenta explícitamente en la metodología.	Permite ejecutar el estudio con rigor sin bloqueos administrativos.
Necesidad del AVC vs. chat	Se reformuló el diseño comparativo para aislar explícitamente el efecto del embodiment: ambas condiciones (A: AVC y B: textual) utilizan exactamente	Responde directamente al cuestionamiento sobre el valor diferencial del AVC.

Aspecto	Cambio realizado	Justificación
	el mismo motor RAG y LLM subyacente. Cualquier diferencia observada se atribuye únicamente a la presencia del agente corporizado y su modalidad comunicativa multimodal.	
Arquitectura técnica	Se amplió la descripción del sistema: se documentaron el módulo AvatarController, el pipeline RAG del backend, el lip sync simulado (eventos SpeechSynthesisUtterance), las expresiones emocionales controladas por el LLM, y el toggle de modo conversacional.	La propuesta original era escueta en detalles de implementación; esta versión muestra viabilidad técnica concreta.


b) Estado Actual del Agente

Descripción del prototipo

Archibot es un agente virtual corporizado (AVC) integrado en **Arca.Xplore**, plataforma web de gestión de expedientes documentales. El prototipo funcional actualmente en operación implementa los tres componentes principales de la arquitectura propuesta:

- **Frontend de renderizado del avatar** (Three.js + @pixiv/three-vrm): avatar 3D visible en el panel derecho de la interfaz.
- **Pipeline RAG backend** (ASP.NET + OpenAI GPT-4o + Vector Store): recuperación semántica y generación de respuestas fundamentadas en el expediente activo.
- **Síntesis de voz** (Web Speech API): narración audible de las respuestas en la condición AVC.

La siguiente captura muestra el sistema en funcionamiento real: el avatar *Arcángel* desplegado junto al visor de PDF del expediente, con el modo conversacional activo. El usuario puede interactuar por voz (botón de micrófono) o texto, y el avatar responde con voz sintetizada y animaciones.



[Figura 1: Archibot en funcionamiento — Avatar Arcángel integrado en Arca.Xplore con expediente activo cargado y modo conversacional activado. Ver repositorio GitHub para captura de pantalla en alta resolución.]

Funcionalidades implementadas vs. pendientes

Funcionalidad	Estado	Notas
Renderizado de avatar 3D (VRM) en navegador	✓ Implementado	Three.js + @pixiv/three-vm; sin dependencias de motor externo
Pose de reposo natural (brazos bajos, cabeza hacia cámara)	✓ Implementado	Aplicada al cargar el modelo desde T-pose
Animaciones idle: respiración, parpadeo, cabeceo	✓ Implementado	Procedurales mediante funciones sinusoidales
Lip sync simulado (blend shapes Aa/Oh)	✓ Implementado	Eventos SpeechSynthesisUtterance (limitación documentada)
Expresiones emocionales controladas por el LLM	✓ Implementado	happy, sad, neutral, surprised, relaxed, angry → VRM blend shapes
Señales visuales de latencia (estado thinking)	✓ Implementado	Animación activa durante recuperación RAG y generación
Pipeline RAG conectado al expediente activo	✓ Implementado	Backend ASP.NET + Vector Store + GPT-4o
Síntesis de voz (TTS) con Web Speech API	✓ Implementado	Activo en Condición A; desactivado en Condición B
Reconocimiento de voz (STT)	✓ Implementado	ArcaSTTCapture; botón de micrófono visible en interfaz
Toggle modo conversacional (Condición A ↔ B)	✓ Implementado	Cambia layout, visibilidad avatar, TTS y STT sin recargar

Funcionalidad	Estado	Notas
Layout responsivo por condición experimental	✓ Implementado	Cond. A: PDF 65% / Avatar 35%; Cond. B: PDF 80% / Chat 20%
Runtime model swapping (intercambio de avatar)	✓ Implementado	URL configurable; permite comparar representaciones visuales
Instrumentos de evaluación (TiA, Godspeed, SUS)	⌚ Pendiente	Formularios por preparar para el piloto
Cuestionario de retención ad-hoc (3 ítems T3)	⌚ Pendiente	Basado en datos verificables del expediente de prueba
Guía del evaluador para el piloto	⌚ Pendiente	Instrucciones de configuración de condición y protocolo
Reclutamiento de participantes expertos	⌚ Pendiente	Mínimo 4 expertos (2 por condición)

c) Diseño Metodológico del Estudio

Tipo de estudio

El estudio es un **piloto con expertos** de diseño *entre-sujetos* (between-subjects) con dos condiciones experimentales:

- **Condición A — Agente Virtual Corporizado (AVC):** el participante interactúa con Archibot (avatar 3D + voz sintetizada + STT + animaciones).
- **Condición B — Interfaz Textual (Baseline):** el participante interactúa con la misma plataforma Arca.Xplore utilizando únicamente el chat textual, sin representación corporal ni voz. El motor RAG y el LLM son idénticos en ambas condiciones.

Justificación del tipo de estudio

Se adoptó un piloto con expertos (en lugar de un estudio con usuarios reales) por dos razones principales: (1) la evaluación con usuarios reales requiere autorización del Comité Ético Científico (CEC) de la UCR, lo que excede el alcance temporal del curso; (2) los expertos en HCI o sistemas documentales son capaces de proporcionar retroalimentación evaluativa estructurada que permite refinar el protocolo para un estudio posterior de mayor escala.

El diseño entre-sujetos evita el efecto de aprendizaje y el sesgo de comparación directa: cada participante experimenta únicamente una condición. La justificación del diseño comparativo es aislar el efecto del *embodiment*: dado que el motor de recuperación y generación es idéntico en ambas condiciones, cualquier diferencia observada se atribuye a la presencia del agente corporizado y su modalidad comunicativa multimodal.

Perfil de participantes

¿Quiénes? Expertos con experiencia profesional o académica en al menos una de las siguientes áreas: Interacción Humano-Computador (HCI), sistemas de recuperación de información, agentes conversacionales, o gestión documental.

¿Cuántos? Se reclutarán un mínimo de **6 participantes** (3 por condición), con el objetivo de alcanzar 8 (4 por condición). Dado el carácter piloto del estudio, el análisis será descriptivo y no busca potencia estadística.

Criterios de inclusión:

- Experiencia demostrable en HCI, sistemas documentales o agentes conversacionales.
- Familiaridad básica con interfaces web de consulta.
- Disponibilidad para una sesión de aproximadamente 45–60 minutos.

Criterios de exclusión:

- Participación previa en el desarrollo de Archibot o Arca.Xplore.
- Conocimiento profundo previo de los reglamentos UCR utilizados como expediente de prueba.

Plan de reclutamiento

Los participantes serán contactados mediante convocatoria directa entre: (1) docentes e investigadores de la Escuela de Ciencias de la Computación e Informática (ECCI-UCR) con publicaciones o proyectos en áreas afines; (2) profesionales de unidades de archivo o gestión documental de instituciones costarricenses. La asignación a condición será aleatoria (sorteo simple).

d) Métricas

La selección de métricas responde directamente a las tres preguntas de investigación del estudio:

Constructo / Métrica	Instrumento	RQ
Confianza percibida en las respuestas del sistema	Trust in Automation (TiA) — Jian et al. (2000); escala Likert 7 puntos, 12 ítems.	RQ1
Naturalidad percibida de la interacción e inteligencia percibida del agente	Godspeed Questionnaire (subescalas Perceived Intelligence y Anthropomorphism) — Bartneck et al. (2009); diferencial semántico 5 puntos.	RQ2
Comprensión / retención de información	Cuestionario de retención ad-hoc (3 ítems opción múltiple con respuesta objetivamente verificable, basados en Tarea T3).	RQ2, RQ3
Usabilidad percibida	System Usability Scale (SUS) — Brooke (1996); Likert 5 puntos, 10 ítems. Puntaje normalizado 0–100.	RQ3
Comportamiento y comentarios espontáneos	Notas estructuradas del evaluador + entrevista semi-estructurada de cierre (3–5 preguntas).	RQ1, RQ2, RQ3

La combinación de TiA + Godspeed + SUS es el estándar más utilizado en la evaluación de AVC según la literatura revisada, lo que facilita la comparabilidad con estudios previos. El cuestionario de retención permite una validación objetiva de la comprensión, independientemente de la percepción subjetiva del usuario.

e) Instrumentos de Recolección de Datos**Trust in Automation (TiA)**

Campo	Detalle
¿Qué mide?	Confianza percibida del usuario en el sistema automatizado; incluye dimensiones de fiabilidad, predictibilidad, competencia percibida y fe en el sistema.
Base bibliográfica	Jian, J.-Y., Bisantz, A. M., & Drury, C. G. (2000). Foundations for an empirically determined scale of trust in automated systems. <i>International Journal of Cognitive Ergonomics</i> , 4(1), 53–71.
¿Cómo se administra?	Cuestionario digital de 12 ítems en escala Likert de 7 puntos (1 = completamente en desacuerdo, 7 = completamente de acuerdo).
¿Cuándo?	Post-tarea T1, inmediatamente después de la consulta de verificación de requisitos.

Godspeed Questionnaire (subescalas seleccionadas)

Campo	Detalle
¿Qué mide?	Naturalidad percibida de la interacción (subescala Perceived Intelligence) y antropomorfismo percibido (subescala Anthropomorphism) del agente virtual.
Base bibliográfica	Bartneck, C., Kulić, D., Croft, E., & Zoghbi, S. (2009). Measurement instruments for the anthropomorphism, animacy, likeability, perceived intelligence, and perceived safety of robots. <i>International Journal of Social Robotics</i> , 1(1), 71–81.
¿Cómo se administra?	Cuestionario digital con diferencial semántico de 5 puntos (pares de adjetivos opuestos). Subescalas: Perceived Intelligence (5 ítems) y Anthropomorphism (5 ítems).
¿Cuándo?	Post-tarea T2, tras la consulta de síntesis que requiere integrar información de dos reglamentos.

System Usability Scale (SUS)

Campo	Detalle
¿Qué mide?	Usabilidad percibida global del sistema; incluye facilidad de uso, aprendizaje y satisfacción general.
Base bibliográfica	Brooke, J. (1996). SUS: A quick and dirty usability scale. <i>Usability Evaluation in Industry</i> , 189(194), 4–7.
¿Cómo se administra?	Cuestionario digital de 10 ítems con escala Likert de 5 puntos. Puntaje normalizado 0–100. Puntajes ≥ 68 se consideran aceptables; ≥ 85 , excelentes.
¿Cuándo?	Post-sesión, una vez finalizadas las tres tareas. Se aplica una única vez por participante.

Cuestionario de Retención de Información (ad-hoc)

Campo	Detalle
¿Qué mide?	Retención efectiva de información específica extraída del expediente durante la interacción. Operacionaliza la comprensión de las respuestas de manera objetivamente verificable.
Base bibliográfica	Diseño ad-hoc basado en datos factuales de los Reglamentos UCR incluidos en el expediente de prueba. Fundamentado en literatura sobre evaluación de comprensión en sistemas de recuperación de información (Fan et al., 2024).
¿Cómo se administra?	3 ítems de opción múltiple (4 alternativas cada uno). Puntaje: 0–3 (1 punto por ítem correcto).

Campo	Detalle
¿Cuándo?	Post-tarea T3, inmediatamente tras la consulta de datos puntuales.

Notas del Evaluador + Entrevista de Cierre

Campo	Detalle
¿Qué mide?	Comportamiento espontáneo, dudas, reacciones no anticipadas y percepción cualitativa del participante sobre la experiencia de interacción.
Base bibliográfica	Observación estructurada estándar en estudios de usabilidad (Nielsen, 1994). Entrevista semi-estructurada de cierre.
¿Cómo se administra?	El evaluador registra observaciones en una hoja de campo predefinida durante la sesión. Al finalizar: entrevista breve de 3–5 preguntas abiertas sobre la experiencia y el agente.
¿Cuándo?	Durante toda la sesión (notas) y al final de la sesión (entrevista).

f) Protocolos de Interacción

El estudio utiliza un **expediente de prueba** compuesto por tres reglamentos oficiales del Consejo Universitario de la UCR: (1) Reglamento de Horas Estudiante, Horas Asistente y Horas Asistente de Posgrado; (2) Reglamento de Régimen Académico Estudiantil; y (3) Reglamento del Trabajo Comunal Universitario. Son documentos públicos, formales y con contenido verificable, representativos del tipo de expedientes gestionados en Arca.Xplore.

Procedimiento general de la sesión

Fase	Actividad	Duración estimada
1. Bienvenida	Presentación del estudio, firma del consentimiento informado, explicación general (sin revelar la hipótesis).	5 min
2. Práctica	El participante explora la interfaz asignada con una pregunta libre. El evaluador resuelve dudas.	5 min
3. Tareas T1–T3	Ejecución secuencial de los tres escenarios con aplicación de instrumentos entre tareas.	25–30 min
4. SUS	Aplicación del System Usability Scale.	5 min
5. Entrevista de cierre	3–5 preguntas abiertas sobre la experiencia general y el agente.	5–10 min
Total		45–55 min

Escenario 1 — Verificación de Requisitos (Tarea T1)

Campo	Detalle
Contexto presentado al participante	“Imagine que es un estudiante de posgrado activo y desea saber si puede ser designado en horas asistente de posgrado. Tiene una nota de Incompleto (IN) en un curso de investigación. Utilice el sistema para responder sus dudas.”

Campo	Detalle
Consulta a realizar	“Soy estudiante de posgrado activo. ¿Puedo ser designado en horas asistente de posgrado si tengo una nota de Incompleto (IN) en un curso de investigación? ¿Cuál es el promedio mínimo que necesito?”
Resultado esperado	El sistema recupera el artículo relevante del Reglamento de Horas y comunica: (a) que la nota IN impide la designación, y (b) el promedio mínimo requerido. La respuesta debe ser factualmente correcta y verificable en el documento.
Instrumento post-tarea	Trust in Automation (TiA) — 12 ítems.
RQ asociada	RQ1 (confianza percibida en la respuesta factual del sistema).
Duración estimada	7–10 minutos.

Escenario 2 — Síntesis Normativa Cruzada (Tarea T2)

Campo	Detalle
Contexto presentado al participante	“Imagine que es un estudiante de bachillerato que desea realizar horas asistente simultáneamente con el Trabajo Comunal Universitario (TCU). Tiene dudas sobre las restricciones de compatibilidad y los límites de horas. Use el sistema para aclarar su situación.”
Consulta a realizar	“Soy estudiante de bachillerato y quiero hacer horas asistente al mismo tiempo que realizo mi TCU. ¿Puedo hacerlo? ¿Hay algún límite de horas combinadas que deba respetar? ¿Cuántas horas de TCU debo cumplir en total?”
Resultado esperado	El sistema integra información de dos reglamentos distintos (Art. 12 del Reglamento de Horas y Art. 20 del Reglamento de TCU) y comunica: (a) si la simultaneidad es posible, (b) el límite de horas combinadas, y (c) el total de horas de TCU requeridas.
Instrumento post-tarea	Godspeed Questionnaire (subescalas Perceived Intelligence y Anthropomorphism).
RQ asociada	RQ2 (naturalidad percibida e inteligencia percibida en tarea de síntesis extendida).
Duración estimada	8–12 minutos.

Escenario 3 — Datos Puntuales y Retención (Tarea T3)

Campo	Detalle
Contexto presentado al participante	“Utilice el sistema para responder las siguientes tres preguntas específicas sobre la normativa. Intente recordar las respuestas: luego se le harán algunas preguntas de verificación.”
Consulta a realizar	“¿Cuánto gana por hora una persona en horas asistente de posgrado en comparación con una en horas estudiante? ¿Cuál es la nota mínima para aprobar un curso en la UCR? ¿Cuántos estudiantes debe tener como mínimo un proyecto de TCU?”
Resultado esperado	El sistema responde con los tres datos factuales puntuales: (a) la relación salarial entre horas asistente de posgrado y horas estudiante; (b) nota mínima aprobatoria de 7.0; (c) mínimo de 8 estudiantes por proyecto de TCU. Datos objetivamente verificables en los reglamentos fuente.
Instrumento post-tarea	Cuestionario de retención ad-hoc (3 ítems de opción múltiple). Luego, al final de la sesión: SUS.
RQ asociada	RQ3 (retención de información y usabilidad percibida).
Duración estimada	7–10 minutos.

Guión de entrevista de cierre

Las siguientes preguntas se formulan al finalizar la sesión. El evaluador puede añadir sondeos (¿“por qué?”, “¿puede dar un ejemplo?”) pero no debe guiar las respuestas:

- **P1:** En términos generales, ¿cómo describiría su experiencia interactuando con el sistema?
- **P2:** ¿Qué tan confiable le pareció la información que el sistema le proporcionó? ¿Por qué?
- **P3:** ¿Hubo algún momento en que la interacción le resultó incómoda, confusa o poco natural? ¿Cuál?
- **P4:** ¿Qué aspectos del sistema cambiaría o mejoraría?
- **P5:** [Solo Condición A] ¿La presencia del avatar y la voz influyeron en su percepción de las respuestas? ¿Cómo?

Referencias seleccionadas

- Bartneck, C., Kulić, D., Croft, E., & Zoghbi, S. (2009). Measurement instruments for the anthropomorphism, animacy, likeability, perceived intelligence, and perceived safety of robots. *International Journal of Social Robotics*, 1(1), 71–81.
- Brooke, J. (1996). SUS: A quick and dirty usability scale. *Usability Evaluation in Industry*, 189(194), 4–7.
- Fan, W. et al. (2024). A Survey on RAG Meeting LLMs: Towards Retrieval-Augmented Large Language Models. *Proc. 30th ACM SIGKDD*. <https://doi.org/10.1145/3637528.3671470>
- Jian, J.-Y., Bisantz, A. M., & Drury, C. G. (2000). Foundations for an empirically determined scale of trust in automated systems. *International Journal of Cognitive Ergonomics*, 4(1), 53–71.
- Jolibois, S., Ito, A., & Nose, T. (2025). The Development of an Emotional Embodied Conversational Agent and the Evaluation of the Effect of Response Delay on User Impression. *Applied Sciences*. <https://doi.org/10.3390/app15084256>
- Wang, I., Smith, J., & Ruiz, J. (2019). Exploring Virtual Agents for Augmented Reality. *Proc. CHI*. <https://doi.org/10.1145/3290605.3300511>