

## Evaluación de la interacción humana con agentes virtuales conectados base de datos de documentos por medio de la técnica RAG

Estudiante: Marco Antonio Jiménez Gutiérrez

Carnet: A42781

### Definición del Problema

Las bases de datos documentales, especialmente aquellas gestionadas mediante técnicas archivísticas, están conformadas por expedientes que agrupan múltiples documentos relacionados entre sí. En este contexto, la técnica de *Retrieval-Augmented Generation* (RAG) permite consultar el contenido de dichos documentos, recuperar información relevante según la consulta realizada y procesarla mediante un modelo de lenguaje de gran tamaño (*Large Language Model*, LLM). Como resultado, el sistema puede generar respuestas contextualizadas, más cercanas a las que ofrecería una persona con experiencia o conocimiento del contenido documental del expediente.

Este enfoque resulta relevante porque la incorporación de un agente virtual corporizado puede ofrecer un punto de interacción más natural para las personas usuarias. A diferencia de los sistemas tradicionales que presentan respuestas únicamente en formato textual, un agente virtual corporizado puede comunicar la información mediante una narración audible, acompañada potencialmente de expresiones, gestos u otros elementos multimodales que favorezcan una experiencia de interacción más humana.

Actualmente, muchos sistemas basados en RAG presentan la información de forma similar a un sistema transaccional o a una interfaz de chat asociada a un repositorio documental. Sin embargo, este tipo de interacción puede resultar limitada cuando se busca una experiencia más cercana, comprensible y socialmente natural. Por ello, surge la pregunta sobre cuál sería el efecto de presentar las respuestas generadas por un sistema RAG a través de un agente virtual corporizado (AVC), especialmente en términos de percepción de confianza,

## Entregable 1: Propuesta de Agente e Investigación

comprensión, naturalidad de la interacción y aceptación por parte de las personas usuarias.

### Revisión Literaria

La literatura consultada para este estudio ofrece una base para justificar la propuesta de un agente virtual inteligente robotizado, entendido como un sistema conversacional con capacidad de razonamiento, recuperación de conocimiento, interacción multimodal y posible representación corporal o robótica. En primer lugar, los estudios sobre Retrieval-Augmented Generation muestran que RAG permite superar una limitación central de los modelos de lenguaje: su dependencia de conocimiento interno, estático y potencialmente desactualizado. Al integrar recuperación de información desde fuentes externas, RAG mejora la pertinencia, actualidad y fundamentación de las respuestas, lo cual resulta esencial para un agente que debe responder consultas de forma confiable y contextualizada [1], [15], [16], [17].

Un hallazgo importante es que el agente no debe limitarse a “generar respuestas”, sino que debe estar conectado a una memoria documental o base de conocimiento verificable. Esto permitiría que las respuestas del agente estén fundamentadas en documentos, datos tabulares, experiencias previas o fuentes institucionales, reduciendo el riesgo de alucinaciones y mejorando la trazabilidad de la información [1], [15], [16]. Además, los enfoques de conversación fundamentada en conocimiento muestran que no basta con recuperar documentos aislados: el sistema debe considerar tanto el contexto local de la conversación como el tema general que guía la interacción, para mantener coherencia y relevancia durante diálogos prolongados [17].

Otro hallazgo clave es la necesidad de personalización y adaptación al usuario. PersonaRAG evidencia que los sistemas RAG tradicionales pueden mejorar cuando incorporan agentes centrados en el usuario, capaces de adaptar la recuperación y generación de respuestas según necesidades, preferencias e interacciones en tiempo real [2]. Este

## Entregable 1: Propuesta de Agente e Investigación

principio es relevante para un agente virtual inteligente robotizado, ya que su efectividad dependerá no solo de responder correctamente, sino de ajustar su estilo comunicativo, nivel de detalle y forma de asistencia al perfil del usuario, contexto de uso y propósito de la consulta [2], [3], [5].

Desde la perspectiva de interacción humano-agente, los estudios revisados coinciden en que el diseño centrado en el usuario es determinante. Un agente conversacional para recuperación de información puede aumentar la confianza, el disfrute y el desempeño de los usuarios cuando se diseña con base en necesidades reales y no como una interfaz genérica [5]. Asimismo, las investigaciones sobre sistemas generativos de recuperación muestran que las interfaces conversacionales pueden reducir el esfuerzo de búsqueda y mejorar la satisfacción del usuario, especialmente en tareas exploratorias, siempre que mantengan credibilidad y apoyen la verificación de la información [10].

La dimensión corporal o “robotizada” del agente también encuentra respaldo en la literatura sobre agentes virtuales encarnados. Los estudios en realidad aumentada y realidad virtual muestran que la presencia visual del agente puede influir en la percepción de inteligencia, confianza, cercanía, utilidad y presencia social [7], [8], [11], [19]. Sin embargo, estos trabajos también advierten que la representación corporal debe diseñarse cuidadosamente: un agente demasiado antropomórfico, poco natural o mal sincronizado puede generar distracción, incomodidad o pérdida de confianza [7], [8], [19]. Por ello, la propuesta debe considerar un diseño visual sobrio, funcional y coherente con la tarea.

La multimodalidad aparece como otro componente central. Un agente inteligente robotizado debería integrar voz, texto, gestos, mirada, expresiones faciales, señalización visual y mecanismos de referencia espacial cuando el contexto lo requiera [4], [8], [11], [12]. La

## Entregable 1: Propuesta de Agente e Investigación

investigación sobre expresiones referenciales multimodales demuestra que los agentes encarnados necesitan combinar lenguaje y gestos para resolver ambigüedades, señalar objetos o aclarar instrucciones en espacios compartidos [4]. En aplicaciones de navegación en ‘*Augmented Reality*’ (AR), la combinación de RAG multiagente, razonamiento espacial y agente encarnado permitió interpretar instrucciones abiertas y guiar al usuario mediante voz y locomoción, con altos niveles de usabilidad reportados [11].

La evidencia también destaca que la naturalidad conversacional depende de mecanismos de gestión del turno, interrupción y latencia. Permitir que el usuario interrumpa verbalmente al agente mejora la eficiencia percibida, la atracción y la sensación de conversación dinámica [6]. Del mismo modo, las pausas, expresiones faciales, gestos y retroalimentación visual pueden mitigar la percepción negativa de la latencia en agentes potenciados por LLMs [9], [13]. Esto es especialmente importante en agentes robotizados, donde la demora entre la pregunta del usuario y la respuesta del sistema puede afectar la sensación de inteligencia, fluidez e inmersión [9], [13].

En dominios sensibles o de alto impacto, como salud, educación, asistencia institucional o servicios públicos, la literatura sugiere que la combinación LLM + RAG + agente multimodal ofrece mejores resultados que los sistemas puramente guionizados o LLM sin recuperación externa. En simulaciones de atención sanitaria en ‘*Virtual Reality*’ (VR), el agente LLM + RAG superó a las variantes guionizadas y LLM-only en éxito de tarea y naturalidad percibida [12]. Este resultado respalda la conveniencia de proponer un agente que combine recuperación semántica, generación lingüística, síntesis de voz, animación facial, gestos y evaluación de desempeño [12].

Finalmente, los trabajos sobre agentes encarnados y simulación muestran que la incorporación de memoria externa, experiencias previas y recuperación de políticas o escenarios puede mejorar la capacidad de

adaptación del agente ante situaciones nuevas [14], [18]. En robótica, los agentes encarnados aumentados por recuperación utilizan bancos de memoria de políticas para seleccionar acciones relevantes según instrucciones y observaciones multimodales [14]. En simulaciones sociales, RAG permite que agentes generativos produzcan interacciones más naturales, coherentes y actualizadas [18]. Asimismo, los estudios longitudinales sobre agentes compañeros subrayan la importancia de estrategias conversacionales adaptativas, memoria persistente y sensibilidad emocional para sostener interacciones significativas en el tiempo [20].

En síntesis, los hallazgos revisados sugieren que la propuesta de un agente virtual inteligente robotizado debe fundamentarse en cinco principios: recuperación de conocimiento verificable mediante RAG [1], [15], [16], [17]; personalización y adaptación contextual [2], [3], [5], [20]; representación corporal cuidadosamente diseñada [7], [8], [11], [19]; interacción multimodal con voz, gestos, emociones y referencias espaciales [4], [8], [9], [12], [13]; y evaluación empírica de confianza, usabilidad, naturalidad, latencia, precisión y satisfacción del usuario [5], [6], [10], [11], [12]. Estos elementos permiten orientar la propuesta hacia un agente no solo conversacional, sino también confiable, explicable, socialmente aceptable y útil en escenarios reales de interacción humano-máquina.

### Preguntas de Investigación

RQ 1: ¿Qué efecto tiene el uso de un agente virtual corporizado como interfaz de un sistema RAG sobre la confianza percibida en las respuestas generadas, en comparación con una interfaz textual de consulta documental?

RQ 2: ¿Qué efecto tiene el uso de un agente virtual corporizado sobre la naturalidad percibida de la interacción y la comprensión de las respuestas en tareas de consulta sobre expedientes documentales, en comparación con una interfaz textual tipo chat?

### Objetivos del agente

1. El primer objetivo del agente es favorecer la confianza percibida por las personas usuarias al presentar respuestas generadas mediante RAG a partir de expedientes documentales. Para ello, el agente actuará como una interfaz explicativa y orientadora, capaz de comunicar la información recuperada de manera clara, contextualizada y cercana, manteniendo coherencia con el contenido documental consultado.
2. El segundo objetivo del agente es mejorar la naturalidad percibida de la interacción y facilitar la comprensión del contenido documental mediante una comunicación corporizada y audible. En lugar de limitarse a mostrar respuestas textuales, el agente buscará representar una forma de consulta más cercana, conversacional y socialmente natural para las personas usuarias que interactúan con expedientes documentales.

### Arquitectura Técnica

La arquitectura técnica propuesta se considera viable para el desarrollo de un prototipo funcional de agente virtual corporizado. El sistema se implementará mediante Unity con exportación WebGL, lo que permitirá ejecutar el agente directamente desde un navegador web. El

## Entregable 1: Propuesta de Agente e Investigación

agente estará representado por un avatar 3D con animaciones básicas de escucha, espera y habla, y funcionará como interfaz de consulta sobre un conjunto documental.

La consulta del usuario será enviada desde la aplicación WebGL hacia un backend seguro, el cual actuará como intermediario entre el cliente y los servicios de OpenAI. Este backend gestionará las solicitudes al modelo de lenguaje y al sistema RAG, evitando exponer credenciales sensibles en el navegador. Para la recuperación documental se utilizarán capacidades de búsqueda sobre archivos y almacenes vectoriales de OpenAI, permitiendo recuperar fragmentos relevantes del conjunto documental antes de generar una respuesta.

Una vez generada la respuesta textual, esta será enviada de regreso al cliente WebGL. Para reducir la latencia de la generación de voz, la narración audible se realizará mediante la síntesis de voz del navegador, utilizando la Web Speech API. De esta manera, el sistema evita depender de un servicio externo adicional de texto a voz y permite que el agente comunique la respuesta de forma oral mientras mantiene una interacción visual mediante el avatar corporizado.

En conjunto, el stack tecnológico propuesto -Unity WebGL, backend seguro, OpenAI para RAG y síntesis de voz del navegador- resulta realista para un prototipo académico orientado a evaluar confianza percibida, naturalidad de interacción y comprensión de respuestas documentales. Su principal limitación técnica será la variabilidad de las voces disponibles en cada navegador y la posible latencia asociada a la recuperación y generación de respuestas, por lo que se recomienda incorporar señales visuales de espera y mecanismos de retroalimentación durante el procesamiento.

## Referencias bibliográficas

- [1] Fan, Wenqi, Yajuan Ding, Liang-Bo Ning, et al. "A Survey on RAG Meeting LLMs: Towards Retrieval-Augmented Large Language Models." Paper presented at Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. May 10, 2024. <https://doi.org/10.1145/3637528.3671470>.
- [2] Zerhoudi, Saber, and Michael Granitzer. PersonaRAG: Enhancing Retrieval-Augmented Generation Systems with User-Centric Agents. July 12, 2024, 1-11.  
<https://doi.org/10.48550/arxiv.2407.09394>.
- [3] More, Atharv. "Interaction via Large Language Models: Advancements in Retrieval-Augmented Intelligent Interfaces." International Journal for Research in Applied Science and Engineering Technology, ahead of print, May 31, 2025.  
<https://doi.org/10.22214/ijraset.2025.70382>.
- [4] Alalyani, Nada, and Nikhil Krishnaswamy. A Methodology for Evaluating Multimodal Referring Expression Generation for Embodied Virtual Agents. In Companion Publication of the 25th International Conference on Multimodal Interaction. 2023.  
<https://doi.org/10.1145/3610661.3616548>.
- [5] Schmitt, Anuschka, Thiemo Wambsganss, and J. Leimeister. "Conversational Agents for Information Retrieval in the Education Domain." Proceedings of the ACM on Human-Computer Interaction 6 (November 2022): 1-22.  
<https://doi.org/10.1145/3555587>.
- [6] Egelhofer, David, Jiafan Gao, Nils Heinsohn, et al. Effects of Verbal Interruption in Conversations with an Intelligent Virtual Agent in Virtual Reality. In Proceedings of the 2025 ACM Symposium on Spatial User Interaction. 2025.  
<https://doi.org/10.1145/3694907.3765918>.



- [7] Wang, Isaac, Jesse Smith, and J. Ruiz. "Exploring Virtual Agents for Augmented Reality." Paper presented at Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems. May 2, 2019. <https://doi.org/10.1145/3290605.3300511>.
- [8] Chang, Zhu, Huidong Bai, Li Zhang, Kunal Gupta, Weiping He, and M. Billinghamurst. The Impact of Virtual Agents' Multimodal Communication on Brain Activity and Cognitive Load in Virtual Reality. 3 (November 2022). <https://doi.org/10.3389/frvir.2022.995090>.
- [9] Jolibois, Simon, Akinori Ito, and Takashi Nose. "The Development of an Emotional Embodied Conversational Agent and the Evaluation of the Effect of Response Delay on User Impression." Applied Sciences, ahead of print, April 11, 2025. <https://doi.org/10.3390/app15084256>.
- [10] Liang, Yidong, Zhijing Wu, Fan Zhang, Dandan Song, and Heyan Huang. "How Users Interact with Generative Information Retrieval Systems: A Study of User Behavior and Search Experience." Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval, ahead of print, 2025. <https://doi.org/10.1145/3726302.3729998>.
- [11] Yang, Hsuan-Kung, Tsu-Ching Hsiao, Ryoichiro Oka, Ryuya Nishino, Satoko Tofukuji, and N. Kobori. "An Embodied AR Navigation Agent: Integrating BIM with Retrieval-Augmented Generation for Language Guidance." 2025 IEEE International Symposium on Mixed and Augmented Reality (ISMAR), August 10, 2025, 1461-71. <https://doi.org/10.1109/ismar67309.2025.00150>.
- [12] Yang, Han, Qiuyu Tian, and Xiaowen Gu. "Toward Industry 5.0: Evaluating Multimodal Virtual Human Interaction for Smart Healthcare in Simulated VR Environments." Internet Technology Letters 9 (December 2025). <https://doi.org/10.1002/itl2.70190>.

- [13] Elfleet, Morad, and Mathieu Chollet. Investigating the Impact of Multimodal Feedback on User-Perceived Latency and Immersion with LLM-Powered Embodied Conversational Agents in Virtual Reality. In Proceedings of the 24th ACM International Conference on Intelligent Virtual Agents. 2024. <https://doi.org/10.1145/3652988.3673965>.
- [14] Zhu, Yichen, Zhicai Ou, Xiaofeng Mou, and Jian Tang. "Retrieval-Augmented Embodied Agents." April 17, 2024, 17985-95. <https://doi.org/10.1109/cvpr52733.2024.01703>.
- [15] Roy, Soham, Mitul Goswami, Nisharg Nargund, S. Mohanty, and P. Pattnaik. "Conversational Text Extraction with Large Language Models Using Retrieval-Augmented Systems." December 19, 2024, 1-6. <https://doi.org/10.1109/cine63708.2024.10881808>.
- [16] Haque, Imam Chalise Rafidhul. "Implementation of Retrieval-Augmented Generation (RAG) and Large Language Models (LLM) for a Document and Tabular-Based Chatbot System." Journal of Electronics Technology Exploration, ahead of print, July 10, 2025. <https://doi.org/10.52465/joetex.v3i1.588>.
- [17] Ahn, Yeonchan, Sang-Goo Lee, Junho Shim, and Jaehui Park. "Retrieval-Augmented Response Generation for Knowledge-Grounded Conversation in the Wild." IEEE Access 10 (2022): 131374-85. <https://doi.org/10.1109/access.2022.3228964>.
- [18] Shimadzu, Hikaru, T. Utsuro, and Daisuke Kitayama. "Retrieval-Augmented Simulacra: Generative Agents for Up-to-Date and Knowledge-Adaptive Simulations." March 18, 2025, 1461-65. <https://doi.org/10.1109/gcce65946.2025.11275306>.
- [19] Koleva, K., Maurizio Vergari, Tanja Kojić, Sebastian Möller, and Jan-Niklas Voigt-Antons. "Influence of Personality and Communication Behavior of a Conversational Agent on User Experience and Social Presence in Augmented Reality." March 14, 2024, 929-30. <https://doi.org/10.1109/vrw62533.2024.00261>.

- [20] Calvo, Rodrigo, Heting Wang, Alexander Barquero, Xuanpu Zhang, Rohith Venkatakrishnan, and Jaime Ruiz. “Exploring Interactions with Companion Virtual Agents.” Proceedings of the 13th International Conference on Human-Agent Interaction (New York, NY, USA), HAI '25, 2026, 274-83.  
<https://doi.org/10.1145/3765766.3765791>.